Capítulo 2

Aprendizado supervisionado e não supervisionado

Segundo Malik (2021), o aprendizado de máquina é um conceito e um dos pilares da inteligência artificial moderna, permitindo que sistemas computacionais aprendam a partir de dados, identifiquem padrões e tomem decisões de forma autônoma. Dentro desse contexto, destacam-se dois paradigmas fundamentais: o aprendizado supervisionado e o aprendizado não supervisionado.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Enquanto o aprendizado supervisionado se baseia em dados rotulados para ensinar modelos a realizar tarefas como classificação e regressão, o aprendizado não supervisionado busca extrair estruturas e agrupamentos ocultos a partir de dados não rotulados.

Compreender esses dois tipos de aprendizado é muito importante para o desenvolvimento de soluções inteligentes aplicáveis a diversas áreas, como saúde, finanças, segurança e marketing. Este capítulo apresenta os principais conceitos, técnicas, métricas de avaliação e desafios associados a cada conceito.

Serão discutidas abordagens diversas, além de problemas comuns na modelagem, como overfitting e underfitting, e estratégias para mitigá-los. Nosso objetivo é oferecer uma base sólida para o entendimento e a aplicação de técnicas de aprendizado supervisionado e não supervisionado em contextos reais de análise de dados e inteligência artificial.

1 Aprendizado supervisionado

Segundo Suave (2024), o aprendizado de máquina é peça-chave para a inteligência artificial, permitindo que sistemas aprendam padrões a partir de dados para realizar tarefas como predição, classificação e agrupamento.

Ele é dividido em dois paradigmas principais: aprendizado supervisionado e não supervisionado. Como já vimos, o aprendizado supervisionado utiliza dados rotulados para treinar modelos, enquanto o aprendizado não supervisionado identifica padrões em dados não rotulados.

Vamos explorar os conceitos, técnicas, métricas de avaliação e desafios comuns desses dois paradigmas, com foco em suas aplicações práticas e soluções para problemas frequentes.

Para Suave (2024), o aprendizado supervisionado é uma das abordagens mais utilizadas em machine learning, no qual modelos são treinados

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

a partir de um conjunto de dados rotulados, em que cada exemplo de entrada está associado a uma saída desejada. O objetivo é fazer com que o modelo aprenda uma função que relacione corretamente as entradas às saídas, permitindo que ele generalize para novos dados não vistos.

1.1 Definição e características principais

Para Suave (2024), o aprendizado supervisionado trata-se de um método comum e caracteriza-se por utilizar dados de treinamento que já possuem respostas desejadas. O objetivo do algoritmo de aprendizado supervisionado é construir um modelo que possua uma resposta correta, mesmo que os dados sejam novos.

IMPORTANTE

Podemos citar como exemplo o algoritmo utilizado no aprendizado supervisionado que já foi treinado. Esse treinamento tem como objetivo reconhecer e categorizar e-mails, sendo um spam ou não, utilizando um conjunto de e-mails que já haviam sido classificados.

Mueller e Massaron (2018) nos explicam que o aprendizado supervisionado é uma abordagem em que um modelo é treinado com um conjunto de dados rotulados, com o objetivo de aprender uma função que mapeie as entradas para as saídas corretas, generalizando para dados não vistos. As principais características incluem:

- Dados rotulados: cada amostra de treinamento contém uma entrada e um rótulo.
- Objetivo: mitigar as chances de erros entre as predições do modelo e os rótulos verdadeiros.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Exemplos de aplicação: diagnóstico médico, previsão de preços e detecção de fraudes.

O aprendizado supervisionado é dividido em dois tipos principais: classificação e regressão, a depender da natureza do rótulo.

1.2 Classificação vs. regressão

A partir de Muller e Guido (2016), veremos de uma forma breve classificação e regressão em aprendizado supervisionado. Na classificação, o objetivo é prever uma categoria ou classe discreta para uma entrada; por exemplo, determinar se um e-mail é ou não um spam. Outro exemplo seria classificar uma imagem como um animal ou objeto. A classificação pode ser binária, em que algo é positivo ou negativo; pode ser multiclasse, em que algo possua mais de uma classe; e também pode ser de multirrótulo, em que algo pertence a múltiplas classes.

Para esse objetivo, pode-se usar alguns algoritmos conhecidos, como árvores de decisão, algoritmo de K-Nearest Neighbors, máquinas de vetores, regressão logística ou até mesmo as redes neurais, que podem ser usadas para classificação de imagens, por exemplo.

O algoritmo de K-Nearest Neighbors classifica ou prevê valores com base na proximidade dos dados e identifica pontos de dados mais próximos de um novo ponto, usando uma métrica de distância. Um exemplo seria classificar uma fruta como maçã ou laranja com base em peso e tamanho.

O uso de máquinas de vetores é um algoritmo de aprendizado supervisionado que encontra o melhor hiperplano para separar classes em um espaço de dados, maximizando a margem entre as classes. Um exemplo prático seria a separação de e-mails como spam ou não spam com base em características, encontrando a melhor linha que divide os dois grupos.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

A regressão logística tem como objetivo a previsão de um valor contínuo, como estimar qual vai ser a temperatura na semana com base nos dados meteorológicos ou saber o valor de um imóvel com base no seu tamanho, localização e dados da vizinhança, modelando a relação entre variáveis de entrada e a probabilidade de uma classe.

Alguns detalhes técnicos importantes sobre a regressão: ela pode ser linear, usando uma relação linear; não linear, utilizando funções complexas; ou regularizada. Alguns algoritmos que podemos citar são o de regressão polinomial, regressão linear ou de Gradient Boosting, que combina previsões de múltiplos modelos fracos.

O Gradient Boosting pode prever a demanda de energia elétrica em uma cidade com base em variáveis como temperatura, dia da semana e feriados, por exemplo. Já a regressão polinomial é utilizada em finanças na previsão de preços de ações, e a regressão linear normalmente é usada em problemas simples, como prever vendas de uma loja com base no número de clientes.

2 Aprendizado não supervisionado

Segundo Suave (2024), diferentemente do aprendizado supervisionado, quando tratamos do aprendizado não supervisionado, estamos lidando com dados que não possuem respostas desejadas.

O uso de aprendizado não supervisionado tem como objetivo a exploração de estruturas de informação; assim, é possível extrair padrões dos dados coletados e até mesmo identificar agrupamentos de dados diversos que podem ser similares.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

2.1 Conceito e aplicações práticas

Para Geron (2019), o aprendizado não supervisionado trata de dados não rotulados, em que o objetivo é identificar padrões ou estruturas inerentes nos dados sem uma saída predefinida, como já vimos anteriormente. O modelo em si explora a distribuição dos dados para agrupar, reduzir a dimensionalidade ou detectar anomalias existentes. Para reforçar nosso conhecimento, vejamos algumas das características principais que o incluem:

- Ausência de rótulos: não há respostas corretas fornecidas durante o treinamento.
- Objetivo: descobrir estruturas ocultas, como grupos semelhantes ou representações compactas dos dados.
- Aplicações práticas:
    - Segmentação de clientes em agrupamento de comportamentos semelhantes.
    - Redução de dimensionalidade para visualização de dados complexos.
    - Detecção de anomalias.

O aprendizado não supervisionado é particularmente considerado mais útil quando os dados são abundantes, mas criar rótulos para eles custa muito caro, tornando esse objetivo inviável.

PARA PENSAR

Você consegue imaginar no nosso dia a dia um exemplo em que haja tantos dados que não possuem rótulo a ponto de tornar-se inviável rotulá-los? Registros de comportamento de massa podem ser um bom exemplo.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Segundo Suave (2024), um exemplo prático para cenários em que não sabemos quais perguntas devem ser feitas de maneira prévia poderia ser o de segmentação de clientes em *marketing*, em que um algoritmo tenta identificar grupos de clientes que possuem comportamentos semelhante sem uma classificação prévia.

2.2 Técnicas de clustering: K-means e DBSCAN

Para Malik (2021), clustering é uma técnica de aprendizado não supervisionado que agrupa dados com base em semelhanças. Falamos agora sobre duas abordagens populares: o K-means e o DBSCAN (density-based spatial clustering of applications with noise).

Já para Silveira e Bullock (2017), são duas técnicas muito utilizadas que possuem destaque de uso em diferentes cenários. Também possuem limitações e vantagens de uso diferentes entre si.

O K-means é um algoritmo popular de agrupamento baseado em participação. Dividem-se os pontos de dados em números de k clusters, sendo eles distintos e não possuindo sobreposição. Já o DBSCAN é uma técnica de aprendizado baseada em densidade, agrupando pontos de dados compactados, utilizando como base uma métrica de distância, não exigindo previamente o número de clusters e sendo possível tratar clusters de forma arbitrária.

2.2.1 K-means:

- Conceito: divide os dados em k grupos, em que k é definido pelo usuário. Cada grupo é representado por um centroide, e os pontos são atribuídos ao centroide mais próximo. Os centroides podem ser considerados o centro de um cluster, em que é calculado a média das coordenadas de todos os pontos de dados atribuídos a um determinado cluster.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Funcionamento:
    - Escolha de k – seleciona-se o número de cluster k.
    - Inicialização de k – os centroides são aleatoriamente colocados em um espaço de dados, sendo um para cada cluster.
    - Atribuição de cada ponto ao centroide – colocar o mais próximo possível, com base em distância euclidiana, cada ponto de dados ao centroide.
    - Recálculo dos centroides – recalcular os centroides, usando como base a média dos pontos atribuídos a cada cluster.
    - Repetir até convergência – repetir as etapas até que os centroides não mudem mais de uma forma significativa.
- Vantagens: simplicidade – de fácil implementação e eficiência computacional. Eficaz quando utilizado para grandes conjuntos de dados em uma determinada tarefa. Pode ser escalável, já que possui bom desempenho com um grande conjunto de clusters e pontos de dados. Intuitivo e com resultados de fácil interpretação, principalmente em apresentação 2D.
- Limitações: requer especificação de um número de k, o que pode ser difícil de determinar. Muito sensível a valores se forem discrepantes. Pode afetar de forma desproporcional a posição de um centroide. Assume que os clusters são esféricos; não indicado para clusters de alta complexidade ou de tamanho irregular.

2.2.2 DBSCAN (density-based spatial clustering of applications with noise)

- Conceito: agrupa pontos com base na densidade, identificando clusters de formatos arbitrários e detectando outliers.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Funcionamento:
    - Definir um raio – define o limite de distância ε e um número mínimo de pontos, os 'MinPts', para formar um cluster.
    - Identifica pontos centrais – identifica pontos centrais, com pelo menos MinPts vizinhos dentro de ε, pontos de borda e ruídos.
    - Expande clusters – a partir de pontos centrais, expande clusters, conectando com seus vizinhos. Qualquer ponto é classificado como ruído quando não pode ser atribuído a um cluster e não faça parte da vizinhança de um ponto central.
- Vantagens: não requer especificação do número de clusters. Pode de maneira automática determinar o número de clusters e lida bem com outliers, que podem ser considerados através de valores discrepantes. É mais versátil quando comparado ao k-means, já que pode identificar agrupamentos de várias formas.
- Limitações: sensível aos parâmetros ε e MinPts. Uma seleção incorreta dos parâmetros pode trazer consequências, como resultados errados. Seu uso não é indicado quando clusters têm densidade variável, além de ter o desempenho reduzido quando utilizado em dados de alta dimensão, já que o conceito de distância fica menos significativo.

Provavelmente teremos melhores resultados utilizando o DBSCAN quando os dados possuírem ruídos, formas irregulares ou principalmente quando não soubermos o número de clusters. No entanto, se soubermos o número de clusters, estivermos utilizando dados limpos e bem estruturados, talvez o ideal seja utilizar o k-means.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

3 Métricas de avaliação de modelos

Para Malik (2021), a avaliação do desempenho de modelos de aprendizado de máquina é essencial para garantir que eles generalizem bem para dados não vistos. As métricas variam conforme o tipo de tarefa, podendo ser de classificação, regressão, entre outras.

3.1 Métricas para classificação: precisão, recall, F1-score

Ainda segundo Malik (2021), podemos definir precisão como uma métrica que avalia o quanto podemos confiar em um modelo em que o objetivo dessa previsão é determinar a qual classe um exemplo pertence.

Um exemplo de precisão é o uso de um modelo que detecta spam. A precisão indica a proporção de e-mails classificados como spam que realmente são spam. Esperamos que a proporção do número de e-mails corretamente identificados seja elevada.

Já o recall, também conhecido como taxa de detecção, baseia-se no número de acertos da classificação, prevendo casos positivos ou não. Um exemplo que podemos utilizar é o de diagnósticos médicos, em que o recall mede a capacidade de identificar todos os casos de uma doença.

O F1-score é uma média harmônica entre precisão e recall, útil para conjuntos de dados desbalanceados. A média harmônica dá mais importância aos valores que são considerados baixos.

Quando o recall e a precisão forem igualmente importantes em um cenário de resolução de um problema, o F1-Score pode ser utilizado. Um exemplo de aplicação é quando temos um recall baixo e uma precisão alta.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

3.2 Métricas para regressão: RMSE, MAE, R^2

Modelos de regressão são muito aplicados em distintos setores da indústria e do conhecimento, como na previsão de vendas, análise de mudanças climáticas e até na estimativa do progresso de doenças.

Para desenvolver esses modelos, é necessário identificar as correlações entre as variáveis explicativas e a variável resposta em um conjunto de dados. Por meio de técnicas de aprendizado de máquina, é realizado o treinamento do modelo; assim, uma vez construído, pode ser utilizado para prever novos valores.

Segundo Malik (2021), as métricas de avaliação de modelos de regressão ajudam a quantificar o desempenho do modelo e identificar pontos de melhoria. As métricas quantificam a proximidade que o modelo tem dos valores reais. Diferentes cálculos são utilizados para medir o erro entre as previsões e os resultados que já foram observados.

Vejamos a seguir alguns desses modelos:

- RMSE (root mean squared error) – mede a raiz quadrada da média dos erros quadráticos entre valores previstos e reais. É sensível a outliers, muito usado em séries temporais por ser mais sensível a maiores erros. Consequência ao processo que produziu. Como exemplo de uso, podemos citar a previsão de preços, em que o RMSE quantifica o erro médio em unidades da variável alvo.
- MAE (mean absolute error) – média dos erros absolutos. Menos sensível a outliers, calculado a partir da média dos erros absolutos; possível quando a utilização do módulo de cada erro é realizada para evitar subestimação, já que o valor é menos afetado por outliers. Um exemplo de uso é na avaliação de previsões de vendas, em que erros grandes não devem ser amplificados.
- R^2 – desvio em relação à variabilidade dos dados, indicando a proporção da variância dos dados. Varia de 0 a 1, com valores

próximos a 1 indicando bom ajuste e de 0 indicando pior qualidade do modelo no ajuste aos dados. É útil em modelos lineares, sendo uma boa métrica inicial para comparar diferentes modelos. Suas limitações estão relacionadas à existência de outliers ou quando existem relações não lineares entre as variáveis.

4 Problemas e soluções comuns em modelagem

Na modelagem, segundo Muller e Guido (2016), é comum enfrentar desafios, como o sobreajuste, também conhecido como overfitting, que ocorre quando o modelo memoriza os dados de treino e não generaliza para novos dados; e o subajuste, também chamado de underfitting, que ocorre quando o modelo é simples demais para capturar padrões.

4.1 Overfitting e underfitting: causas e soluções

O overfitting, segundo Muller e Guido (2016), ocorre quando o modelo se ajusta excessivamente aos dados de treinamento, capturando ruídos em vez de padrões gerais, o que resulta em alto desempenho no treinamento, mas baixa generalização para novos dados.

- Causas: modelo muito complexo. Um exemplo são muitas camadas em uma rede neural. Outra possibilidade são poucos dados de treinamento e features irrelevantes ou redundantes.
    - Soluções: realização de técnicas de regularização como L1/L2 (lasso/ridge) ou dropout em redes neurais para limitar a complexidade do modelo. Ainda pode ser feita uma validação cruzada, em que se dividem os dados em k subconjuntos para avaliar a generalização. Outra ação possível seria o aumento de dados, como técnicas de rotação de imagens ou geração de dados sintéticos para aumentar o conjunto de treinamento.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Também há a possibilidade de seleção de features, reduzindo a dimensionalidade e eliminando variáveis irrelevantes.

O underfitting, segundo Muller e Guido (2016), ocorre quando o modelo é simples demais para capturar os padrões dos dados, resultando em baixo desempenho tanto no treinamento quanto no teste.

- Causas: modelo muito simples – por exemplo, uso de regressão linear para dados não lineares; e pouco tempo de treinamento ou hiperparâmetros mal ajustados. Também podemos citar dados de baixa qualidade ou insuficientes.

- Soluções: aumentar a complexidade do modelo, utilizando algoritmos mais robustos, como redes neurais ou árvores de decisão. Também podemos ajustar hiperparâmetros, otimizando parâmetros como taxa de aprendizado ou profundidade da árvore. Além disso, podemos aplicar o pré-processamento de dados para normalizar, escalonar ou limpar os dados, melhorando a qualidade deles.

4.2 Métodos de validação cruzada

Segundo Silveira e Bullock (2017), a validação cruzada é uma técnica para avaliar a capacidade de generalização de um modelo, minimizando o risco de overfitting. Ela divide os dados em subconjuntos para treinamento e teste, garantindo uma avaliação robusta.

A validação cruzada é essencial para selecionar modelos robustos e evitar avaliações enviesadas. Os métodos mais comuns utilizados são:

- K-Fold Cross-Validation: divide os dados em k subconjuntos de tamanho igual. Esses subconjuntos são conhecidos como folds. Treinamos o modelo em k-1 folds e testamos no fold restante, repetindo k vezes. A métrica final é a média dos resultados em cada fold.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

    - Vantagens: usa todos os dados para treinamento e teste, reduzindo viés.
    - Exemplo: em um conjunto de 1000 amostras com k = 5, cada fold tem 200 amostras, sendo o modelo treinado/testado 5 vezes.
- Stratified K-Fold: similar ao K-Fold, mas mantém a proporção das classes em cada fold; ideal para dados desbalanceados.
    - Exemplo: em classificação de doenças raras, garante que amostras positivas estejam distribuídas de maneira uniforme.
- Leave-One-Out (LOO): usa uma única amostra como conjunto de teste e o restante para treinamento, repetindo para todas as amostras.
    - Vantagens: maximiza o uso de dados para treinamento.
    - Limitações: computacionalmente caro para grandes conjuntos de dados.
- Hold-Out: divide os dados, por exemplo, em treinamento 70% e teste 30% uma única vez.
    - Vantagens: simples e rápido.
    - Limitações: sensível à escolha do conjunto de teste.

4.3 Escolha de hiperparâmetros e ajustes

Para Silveira e Bullock (2017), os hiperparâmetros são configurações do modelo que não são aprendidas durante o treinamento, como taxa de aprendizado, número de camadas em redes neurais ou profundidade de árvores de decisão.

A escolha adequada de hiperparâmetros é crucial para o desempenho do modelo. Vejamos a seguir métodos comuns:

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Grid Search: testa todas as combinações de hiperparâmetros em um intervalo predefinido.
    - Exemplo: podemos citar uma rede neural, que testa combinações de taxas de aprendizado e número de neurônios.
    - Vantagens: explora exaustivamente o espaço de hiperparâmetros.
    - Limitações: computacionalmente caro; usado em muitas vezes para grandes conjuntos.
- Random Search: testa combinações aleatórias de hiperparâmetros dentro de intervalos definidos.
    - Vantagens: mais eficiente que Grid Search, especialmente em espaços de alta dimensão.
    - Exemplo: escolhe aleatoriamente taxas de aprendizado e tamanhos de batch; em outras palavras, trata-se de um subconjunto de dados do conjunto de treinamento usado para atualizar parâmetros.
- Otimização bayesiana: usa modelos probabilísticos para prever combinações promissoras de hiperparâmetros.
    - Vantagens: mais eficiente que Grid Search e Random Search.
    - Exemplo: ferramentas como Optuna ou Hyperopt ajustam hiperparâmetros em tempo real.
- Validação cruzada em ajuste: combina validação cruzada com busca de hiperparâmetros para garantir generalização. Um exemplo é a utilização de Grid Search com K-Fold para encontrar a melhor taxa de aprendizado.

Um fator importante para a escolha de hiperparâmetros deve ser guiada por métricas de desempenho que estejam de acordo com o esperado e que possa balancear complexidade computacional com eficácia do modelo.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Considerações finais

Neste capítulo, oferecemos um resumo sobre aprendizado supervisionado e não supervisionado. O aprendizado supervisionado é ideal para tarefas com dados rotulados, como classificação e regressão, enquanto o aprendizado não supervisionado explora dados não rotulados, como em clustering com K-means e DBSCAN.

Por fim, encerramos mostrando métricas como precisão, recall, F1-score, RMSE, MAE e R^2, que avaliam o desempenho, enquanto técnicas como validação cruzada e ajuste de hiperparâmetros garantem robustez e generalização. Problemas como overfitting e underfitting podem ser mitigados com regularização e aumento de dados.

Referências

GERON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**: Concepts, Tools, and Techniques to Build Intelligent Systems. [*S. l.*]: O'Reilly Media, 2019.

MALIK, H. *et al*. **AI and Machine Learning Paradigms for Health Monitoring System**. Varsóvia: Springer, 2021.

MÜLLER, A. C.; GUIDO, Sarah. **Introduction to machine learning with Python**: a guide for data scientists. Sebastopol: O'Reilly Media, 2016.

MUELLER, J. P.; MASSARON, L. **Artificial Intelligence For Dummies**. Hoboken: For Dummies, 2018.

SILVEIRA, G.; BULLOCK, B. **Machine learning**: introdução à classificação. São Paulo: Casa do Código, 2017.

SUAVE, A. A. **Inteligência artificial**. São Paulo: Editora Freitas Bastos, 2024.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.