

Deep learning em ambientes multicloud

Segundo Thummarakoti (2025), na última década, o deep learning tem sido uma ferramenta importante em diversas áreas, contribuindo com a transformação criada pela inteligência artificial e possibilitando muitos avanços em visão computacional, processamento de linguagem natural, sistemas autônomos e em uma infinidade de outras aplicações.

No entanto, os algoritmos modernos de aprendizado profundo demandam grande capacidade computacional. Segundo Suave (2024), armazenamento escalável e infraestruturas flexíveis são fatores que impulsionaram a adoção de ambientes de computação em nuvem.

Nesse cenário, o conceito de multicloud surge como uma opção robusta para potencializar projetos de inteligência artificial. Em vez de depender de um único provedor, empresas e pesquisadores utilizam simultaneamente diversas plataformas de nuvem, como AWS, Azure, Google Cloud e outros, aproveitando o que cada uma oferece de melhor, seja em termos de custo, desempenho, disponibilidade de recursos especializados ou conformidade regulatória.

A integração entre deep learning e multicloud não apenas amplia a capacidade de processamento, mas garante resiliência, flexibilidade e otimização de custos. Ao mesmo tempo, introduz desafios importantes relacionados à orquestração de recursos distribuídos, interoperabilidade entre provedores, segurança da informação e governança de dados.

1 Conceitos básicos de multicloud

Para Thummarakoti (2025), o deep learning tem revolucionado a inteligência artificial, permitindo avanços em áreas como visão computacional, processamento de linguagem natural e sistemas de recomendação.

Segundo Goodfellow, Bengio e Courville (2016), deep learning é uma subárea do machine learning que se concentra no uso de redes neurais artificiais com múltiplas camadas para modelar e resolver problemas complexos a partir de grandes quantidades de dados. Podemos citar como exemplo um modelo de extração que retire representações diretamente dos dados brutos, como imagens, áudio ou texto.

No entanto, sua implementação em larga escala demanda recursos computacionais intensivos, como GPUs (graphics processing units) e TPUs (tensor processing units), que são frequentemente provisionados em ambientes de nuvem. O multicloud não só evita o vendor lock-in, uma dependência excessiva de um único provedor de serviços de nuvem, mas facilita a adoção de tecnologias especializadas de cada provedor, como ferramentas de machine learning otimizadas.

Segundo Chandrasekaran (2014), o conceito de multicloud é relacionado à utilização estratégica de serviços de computação em nuvem em diferentes provedores de serviço, permitindo que organizações distribuam cargas de trabalho e recursos entre plataformas distintas, como AWS, Azure e Google Cloud.

Essa medida busca aumentar a segurança estratégica, evitar dependência excessiva de um único fornecedor e otimizar custos, ao mesmo tempo que possibilita maior flexibilidade e escalabilidade.

Entre as principais vantagens do multicloud podemos citar a diminuição de riscos associados a falhas em um provedor específico e a liberdade para escolher soluções mais adequadas a cada tipo de aplicação ou necessidade empresarial.

Para Ferreira (2024), um ambiente multicloud envolve a orquestração de serviços de computação, armazenamento e rede de vários provedores de nuvem, permitindo uma abordagem híbrida que combina os melhores recursos disponíveis.

Vejamos um exemplo próximo da realidade para contextualizar o tema. Imagine uma equipe de deep learning usando uma ferramenta da AWS para treinamento de modelos, o Azure para inferência em tempo real e o Google para análise de dados, conforme figura 1 a seguir.

Figura 1 – Exemplo de uso multicloud



Essa estratégia é particularmente valiosa para deep learning devido à necessidade de lidar com datasets massivos e computações paralelas, em que um único provedor pode não oferecer o equilíbrio ideal entre custo, desempenho e disponibilidade.

Segundo Ferreira (2024), existem projeções que indicam um grande crescimento nos próximos anos no mercado de multicloud relacionado a inteligência artificial e deep learning; algo próximo de US\$ 30,0 bilhões.

O multicloud promove inovação ao permitir experimentos com ferramentas especializadas, como treinamento eficiente de transformadores, reduzindo tempos de iteração em comparação com setups de nuvem única. Além disso, ele mitiga riscos de downtime regional, que ocorre quando um datacenter de um provedor de nuvem fica indisponível em uma determinada região, mas não em outras, garantindo continuidade em aplicações críticas de inteligência artificial, como sistemas de saúde preditiva.

1.1 Vantagens e desafios de integrar vários provedores de nuvem

Quando falamos sobre as vantagens em integrar vários provedores de nuvem nas nossas atividades profissionais ou de estudos, precisamos pensar não somente nos benefícios práticos, mas na viabilidade de aplicá-las. Lembrando que muitas vezes é necessário ter uma equipe multidisciplinar ou profissionais altamente qualificados e com muita experiência para observar demandas mais complexas envolvendo vários provedores de nuvem.

Segundo Thummarakoti (2025), as vantagens em integrar vários provedores incluem a flexibilidade para selecionar serviços otimizados; por exemplo, instâncias de GPU na AWS para treinamento intensivo ou ferramentas de automação de machine learning no Azure, o que pode levar a reduções de custo por meio de negociações competitivas.

Outro benefício que podemos citar como exemplo está relacionado a uma maior resiliência contra falhas, já que estamos trabalhando com vários provedores de serviço de nuvem. Talvez seja interessante possuir uma redundância em provedores diferentes, ou até mesmo geograficamente distintos em relação aos seus datacenters.

Outro ponto possível de aproveitar é a conformidade com regulamentações globais, pois, trabalhando com mais opções de serviços em nuvem, abre-se um leque maior de ferramentas. Assim, em teoria, temos um campo mais abrangente para estar em conformidade com regulamentações globais e acesso a inovações específicas; por exemplo, uma integração de machine learning para segurança multicloud que atenda normas empresariais ou governamentais.

No entanto, desafios que podem estar relacionados envolvem a complexidade de gerenciamento de uma ou mais API (application programming interface) heterogênea, até mesmo potenciais aumentos em custos de transferência ou armazenamento de dados, além dos riscos de segurança ampliados, como brechas em configurações inconsistentes, aumentando ainda mais a necessidade de uma equipe profissional bem-preparada.

Para exemplificar a adoção de uma atividade que pode ser realizada para mitigar alguns desses riscos, as organizações podem adotar o uso de ferramentas unificadas como o Kubernetes para orquestração. As organizações podem enfrentar problemas como latência em comunicações cross-cloud – uma estratégia de computação em nuvem que realiza a execução dessas comunicações – em diferentes componentes de uma aplicação ou carga de trabalho em várias plataformas de nuvem. A latência em comunicações cross-cloud podem, por exemplo, impactar a arquitetura de aprendizado profundo de uma inteligência artificial, como no treinamento distribuído de modelos como GANs (generative adversarial networks) ou LLMs (large language models).

1.2 Tipos de serviços em nuvem aplicáveis ao deep learning

Segundo Thummarakoti (2025), alguns dos tipos de serviços são aplicáveis ao deep learning em nuvens computacionais. Podemos citar os mais relevantes:

- Serviço de computação: instâncias aceleradas por hardware, com um servidor de nuvem computacional que atenda a uma necessidade específica, como no uso de uma rede neural convolucional. Um exemplo seria o uso de GPUs NVIDIA na AWS para o treinamento da rede ou Google Cloud TPUs v4 para modelos de linguagem em escala, oferecendo maior desempenho em tarefas de NLP (natural language processing).
- Serviço de armazenamento: soluções escaláveis como Amazon S3 para dados não estruturados podem ser utilizadas para integração dos pipelines com machine learning. Pode ser aconselhado o uso do Azure Blob ou Google Cloud Storage para acesso de alta velocidade aos dados armazenados.
- Orquestração: ferramentas como AWS SageMaker para end-to-end machine learning workflows, ou seja, todo o ciclo que cobre desde a coleta e preparação de dados até a implantação e o monitoramento de modelos em produção. Vale como exemplo também o kubernetes em multicloud para gerenciamento de clusters distribuídos, unificando e administrando aplicações em contêineres que estão espalhadas por diferentes provedores de nuvem.
- Serviços de inteligência artificial gerenciados: temos como exemplo o uso do AWS Rekognition para visão computacional, Google AutoML para automação de hiperparâmetros ou Azure Cognitive para usar modelos pré-treinados de NLP de forma escalável. Esses serviços facilitam a escalabilidade, permitindo que modelos de deep learning sejam treinados com eficiência energética aprimorada.

2 Treinamento distribuído na nuvem

Para Thummarakoti (2025), treinamento distribuído na nuvem consiste em dividir a execução de modelos de aprendizado de máquina entre múltiplas instâncias de computação, permitindo que grandes volumes de dados e redes neurais complexas sejam processados de forma paralela e escalável e fazendo com que exista de forma significativa a redução do tempo de treinamento, aproveitando a elasticidade dos recursos de provedores de nuvem.

2.1 Estratégias de paralelização de dados e modelos

O treinamento distribuído acelera o processamento de deep learning dividindo tarefas em múltiplas instâncias do cross-cloud, segundo Thummarakoti (2025). A paralelização de dados consiste na estratégia de dividir o dataset em subsets que são distribuídos entre múltiplos nós de processamento, permitindo que cada nó realize cálculos de forma independente sobre seu subconjunto de dados.

Os gradientes calculados localmente são posteriormente sincronizados, utilizando técnicas como Parameter Server ou AllReduce:

- **Parameter Server** – um ou mais servidores centrais que armazenam os parâmetros do modelo, tendo como vantagens fácil implementação e escalabilidade em clusters heterogêneos; mas pode sofrer com maior latência.
- **AllReduce** – os nós compartilham os gradientes diretamente entre si, usando operações de redução distribuída sem depender de um servidor central. Cada nó acaba com os mesmos parâmetros atualizados após a operação, evita gargalos e tem um bom desempenho em grandes clusters; porém, é mais difícil de implementar.

O uso de tais técnicas garante que o modelo final aprenda de maneira consistente a partir de todos os dados. Tais métodos são especialmente eficientes para conjuntos de dados grandes, como ImageNet, um grande banco de dados de imagens, e pode ser escalado horizontalmente em clusters de GPUs ou TPUs, acelerando significativamente o treinamento sem alterar a arquitetura do modelo.

Sobre a paralelização de modelos, podemos dizer que, ao contrário da abordagem anterior, esta técnica divide o próprio modelo entre diferentes dispositivos. Camadas ou blocos de uma rede neural são atribuídos a GPUs ou nós distintos, permitindo que modelos muito grandes, como LLMs (large language models) acima de 100 GB de parâmetros, sejam treinados mesmo quando não cabem na memória de um único dispositivo.

Embora seu uso seja considerado mais complexo, a paralelização de modelos é essencial para arquiteturas profundas e volumosas, podendo ser combinada com paralelismo de dados em estratégias híbridas, especialmente em ambientes multicloud, para otimização de desempenho, uso de recursos e redução do custo.

2.2 Introdução a Horovod e TensorFlow Distributed

Para Geron (2019), o Horovod e o TensorFlow Distributed são frameworks muito utilizados para treinamento distribuído de modelos de deep learning. Seu uso é indicado em especial para ambientes com múltiplas GPUs ou clusters multicloud.

O Horovod foi desenvolvido inicialmente pela empresa Uber. Ele facilita a implementação de paralelismo de dados usando operações de all-reduce, permitindo que todos os nós compartilhem gradientes de forma eficiente sem depender de um servidor central, técnica que já vimos anteriormente.

Já o TensorFlow Distributed é a solução nativa do TensorFlow para treinamento distribuído, oferecendo estratégias como MirroredStrategy para múltiplas GPUs locais e MultiWorkerMirroredStrategy para clusters distribuídos. O uso de ambas as estratégias visa reduzir o tempo de treinamento e aumentar a escalabilidade, mantendo consistência na atualização dos parâmetros do modelo.

3 Gerenciamento de dados em multicloud

Segundo Ferreira (2025), no contexto de multicloud, o gerenciamento de dados envolve coordenar o armazenamento, a movimentação e o acesso a informações distribuídas entre diferentes provedores de nuvem, o que pode ser uma estratégia eficiente.

Para Thummarakoti (2025), estratégias eficientes incluem replicação de dados, particionamento inteligente e políticas de consistência, garantindo que aplicações de deep learning acessem dados de forma rápida e confiável. Além disso, é essencial considerar custos de transferência, latência e segurança, especialmente ao combinar serviços de nuvens distintas, como Azure e AWS ou Google Cloud para otimizar desempenho e escalabilidade.

Em ambientes multicloud, o armazenamento de grandes datasets exige soluções capazes de lidar com volumes massivos de dados usados em treinamentos de deep learning, como sabemos.

Serviços de armazenamento em nuvem, como Amazon S3, Azure Blob Storage e Google Cloud Storage, oferecem alta durabilidade e disponibilidade, permitindo que datasets sejam acessados de maneira simultânea por múltiplos nós de processamento. Estratégias como sharding, que faz a divisão de dados em partes menores, e a compressão eficiente ajudam a reduzir custos e acelerar transferências entre regiões ou provedores. Quando falamos em uso empresarial ou de pesquisa, o custo é um elemento muito importante.

A movimentação de dados entre nuvens deve ser cuidadosamente planejada para minimizar latência e gargalos de rede. Técnicas de replicação seletiva, pré-carregamento de dados e uso de caches locais permitem que grandes volumes de informações sejam processados de forma contínua, garantindo que GPUs e TPUs permaneçam ocupadas sem interrupções. Além disso, políticas de segurança e criptografia são essenciais para proteger dados sensíveis durante o tráfego e armazenamento em múltiplos ambientes, já que não adianta ter eficiência sem segurança quando pensamos em ambientes corporativos.

Chandrasekaran (2014) nos ensina que algumas técnicas podem nos ajudar a reduzir o tamanho dos arquivos sem perda significativa de informação, acelerando transferências e reduzindo custos de armazenamento, em ambientes de múltiplos servidores de nuvem computacional.

Tais técnicas, aliadas a compressão e estratégias de transferência eficiente, como pré-carregamento de dados, streaming, uso de caches locais e paralelismo na movimentação de arquivos, permitem que clusters de treinamento acessem os dados de forma contínua, minimizando gargalos de rede e garantindo alto desempenho em operações de deep learning distribuído.

Tanto Brotli quanto LZ4 são exemplos de algoritmos de compressão eficientes que podem ser usados para reduzir o tamanho de grandes datasets em ambientes de treinamento distribuído.

3.1 Monitoramento e escalabilidade

Para Chandrasekaran (2014), o monitoramento e a escalabilidade são instrumentos fundamentais em ambientes multicloud para garantir, por exemplo, que clusters de treinamento de deep learning operem de forma eficiente.

Ferramentas de monitoramento acompanham uso de CPU (central processing unit), GPU (graphic processing unit), memória e largura de

banda, permitindo identificar gargalos e ajustar recursos em tempo real. Já a escalabilidade assegura que a infraestrutura acompanhe variações de demanda, mantendo desempenho consistente e otimizando custos sem interrupções no processamento computacional.

3.2 Ferramentas para monitorar o uso de recursos

A obra de Thummarakoti (2025) ensina que o monitoramento eficiente de recursos em ambientes multicloud é essencial para identificar gargalos, otimizar desempenho e controlar custos durante o treinamento de modelos de deep learning.

Ferramentas como Datadog e New Relic oferecem monitoramento em tempo real de CPU, GPU, memória, tráfego de rede e latência, permitindo dashboards personalizáveis e alertas automáticos para situações críticas, que podem ser muito úteis no dia a dia.

Já soluções como CloudZero focam no monitoramento de custos e eficiência de uso de recursos, ajudando equipes a entender como diferentes workloads impactam financeiramente a infraestrutura multicloud. O uso combinado dessas ferramentas possibilita visibilidade quase completa da operação, garantindo que clusters distribuídos mantenham desempenho ideal e continuem escaláveis conforme a necessidade da implantação.

3.3 Balanceamento de carga entre diferentes provedores de nuvem

Para Chandrasekaran (2014), o balanceamento de carga em ambientes multicloud é algo muito importante para distribuir tráfego e workloads de forma eficiente entre diferentes provedores de nuvem, mas que, de novo, necessita de profissionais qualificados para sua aplicação.

Para Thummarakoti (2025), garantir alta disponibilidade e desempenho consistente, requer o uso de ferramentas certas e uma boa dose de expertise da equipe de implantação e gerenciamento da nuvem.

Ferramentas como NGINX e F5 permitem gerenciar tráfego de entrada, direcionando solicitações para servidores ou clusters menos sobrecarregados, enquanto oferecem recursos avançados como SSL termination para descriptografar o tráfego e health checks para verificações automáticas dos balanceadores de carga, para garantir que os servidores ou nós de aplicação estejam funcionando corretamente.

Já o Kubernetes Federation possibilita a orquestração de múltiplos clusters distribuídos em diferentes nuvens, permitindo que aplicações sejam escaladas automaticamente e que cargas de trabalho críticas sejam balanceadas globalmente, minimizando as chances de gargalos.



PARA PENSAR

Essas soluções combinadas permitem que sistemas multicloud operem de forma contínua, eficiente e com menor chances de falhas, mitigando eventuais problemas com desempenho e segurança. Mas como um profissional de computação em nuvem deve se preparar para estar apto a aplicar essas ferramentas no seu dia a dia?

3.4 Soluções para minimizar latência

Segundo Thummarakoti (2025), em ambientes multicloud, a latência pode impactar o desempenho de aplicações e treinamentos em inteligência artificial. Para minimizar o risco, podemos usar estratégias como replicação de dados próxima aos clusters de processamento, uso de caches locais ou distribuídos e redes de alta velocidade entre regiões e provedores de nuvem.

Outras soluções incluem CDNs (content delivery networks) para distribuir conteúdo de forma geograficamente eficiente e técnicas de compressão e streaming de dados, que reduzem o volume de informações trafegadas. A combinação dessas práticas garante que GPUs e TPUs recebam dados de forma contínua, mantendo pipelines de treinamento eficientes e com menor tempo de resposta.

O AWS CloudFront é uma CDN que replica dados e conteúdos em múltiplas regiões do mundo, permitindo que usuários e clusters de processamento acessem informações de servidores geograficamente próximos.



PARA SABER MAIS

Para saber mais sobre como configurar, otimizar e proteger distribuições de conteúdo com AWS CloudFront, pesquise a publicação oficial da Amazon Web Services (AWS), que fornece guias detalhados sobre segurança, performance e práticas recomendadas.

Já o QUIC é um protocolo de transporte baseado em UDP (user datagram protocol), projetado para reduzir o tempo de estabelecimento de conexão e melhorar a transferência de dados em redes instáveis, tornando o tráfego mais rápido e confiável em comparação com protocolos tradicionais como TCP/TLS.

4 Boas práticas em ambientes multicloud

Segundo Ferreira (2025), a adoção de ambientes multicloud exige atenção a práticas que garantam desempenho, segurança e eficiência de custos. Entre as principais recomendações estão a padronização de processos e APIs entre diferentes provedores, facilitando a portabilidade de aplicações e dados; o monitoramento contínuo de recursos e custos, utilizando ferramentas como New Relic e CloudZero; e a implementação

de estratégias de redundância e backup para assegurar disponibilidade em caso de falhas.

Já Thummarakoti (2025) ensina que, além disso, é importante adotar políticas de segurança consistentes, incluindo criptografia de dados em trânsito e em repouso, gerenciamento de identidade e acesso centralizado e práticas de conformidade regulatória.

Em ambiente multicloud, adotar modelo zero-trust com verificação contínua garante que nenhum usuário ou serviço seja automaticamente confiável, exigindo autenticação e autorização constantes, mesmo dentro de uma rede corporativa.

Fazer uso de recursos de encriptação gerenciada, que criptografa dados em trânsito e em repouso, utilizando chaves gerenciadas pelo provedor de nuvem ou soluções próprias, pode em muito reduzir riscos de vazamento.

Por fim, o DSPM (data security posture management) fornece visibilidade contínua sobre dados sensíveis, ajudando a identificar riscos, monitorar conformidade e aplicar políticas de proteção de uma forma centralizada.

4.1 Segurança e compliance em soluções multicloud

Para Mishra (2023), em ambientes multicloud, a segurança e o compliance exigem uma abordagem integrada e de forma consistente, dado que dados e aplicações estão distribuídos entre diferentes provedores de nuvem. Boas práticas incluem a adoção do modelo zero-trust, com verificação contínua de usuários e serviços, como falamos.

O uso de uma autenticação forte e políticas de acesso baseadas em identidade podem ser requisitos importantes a serem exigidos. A criptografia gerenciada de dados em trânsito e em repouso garante que informações sensíveis permaneçam protegidas, enquanto o uso de DSPM

permite monitorar a exposição de dados e aplicar políticas de segurança de forma centralizada.

Além da segurança, o compliance regulatório pode ser fundamental, considerando normas como LGPD (Lei Geral de Proteção de Dados), GDPR (General Data Protection Regulation) e HIPAA (Health Insurance Portability and Accountability Act), que exigem governança, auditoria e rastreabilidade de dados e podem ser exigidas em determinadas regiões globais.

Ferramentas de monitoramento e gerenciamento de custos também ajudam a identificar riscos operacionais e garantir que workloads e dados estejam alinhados às políticas corporativas e legais. A combinação dessas estratégias assegura que soluções multicloud operem de maneira mais segura e em conformidade, minimizando vulnerabilidades e protegendo a integridade dos dados.

4.2 Redundância e tolerância a falhas

Em ambientes multicloud, implementar redundância e tolerância a falhas pode ser essencial para garantir alta disponibilidade e continuidade dos serviços, até mesmo garantir a sobrevivência de uma empresa, segundo Thummarakoti (2025).

A redundância envolve manter cópias duplicadas de dados, aplicações e infraestrutura em múltiplos provedores ou regiões de nuvem. Sendo assim, em caso de falha em um recurso, outro profissional pode assumir imediatamente sem interrupção perceptível para o usuário.

A tolerância a falhas está relacionada à capacidade dos sistemas de continuar operando corretamente mesmo diante de falhas parciais. Isso é alcançado por meio de arquiteturas como clusters distribuídos, replicação de dados em tempo real e failover automático, um mecanismo para garantir continuidade de serviço em caso de falha de um componente.

Combinadas, essas práticas garantem que workloads críticos, pipelines de treinamento e aplicações corporativas mantenham desempenho contínuo, confiabilidade e segurança, minimizando impactos de interrupções ou falhas em qualquer provedor de nuvem, fugindo de grandes problemas com clientes, como multas milionárias, dependendo do contrato de serviço assinado.

Considerações finais

Neste capítulo, exploramos o uso de deep learning em ambientes multicloud, destacando conceitos fundamentais e estratégias para aproveitar múltiplos provedores de nuvem de forma mais eficiente. Começamos apresentando os conceitos básicos de multicloud, incluindo suas vantagens e desafios, e como diferentes tipos de serviços em nuvem podem ser aplicados para suportar cargas de trabalho de deep learning.

Em seguida, discutimos o treinamento distribuído na nuvem, detalhando estratégias de paralelização de dados e modelos e apresentando ferramentas como Horovod e TensorFlow Distributed, que permitem acelerar o processamento de grandes datasets e treinar modelos complexos.

Vimos ainda o gerenciamento de dados em multicloud, que foi destacado como crítico, incluindo técnicas de armazenamento, compressão e transferência eficiente de dados usando algoritmos modernos, garantindo que a infraestrutura suporte pipelines de treinamento contínuos e escaláveis.

Abordamos também monitoramento e escalabilidade, com ênfase em ferramentas para monitorar o uso de recursos, balanceamento de carga entre provedores e soluções para minimizar latência, buscando, assim, melhor desempenho de forma consistente, até mesmo em ambientes distribuídos.

Por fim, discutimos boas práticas em ambientes multicloud, com foco em segurança e compliance, incluindo a adoção de modelos de zero-trust, criptografia gerenciada e DSPM, além de estratégias de redundância e tolerância a falhas para manter alta disponibilidade da infraestrutura.

Referências

CHANDRASEKARAN, K. **Essentials of cloud computing**. Boca Raton: Pearson Education, 2023.

FERREIRA, H. **Cloud Computing**. 1. ed. São Paulo: Editora Senac São Paulo, 2025. (Série Universitária.)

GERON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. [S. l.]: O'Reilly Media, 2019.

GOODFELLOW, I; BENGIO, Y; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016.

MISHRA, A. **Cloud Security Handbook for Architects: Practical Guide to Securing Cloud Environments**. Packt Publishing, 2023.

SILVEIRA, G.; BULLOCK, B. **Machine learning: introdução à classificação**. São Paulo: Casa do Código, 2017.

SUAVE, A. A. **Inteligência artificial**. São Paulo: Editora Freitas Bastos, 2024.

THUMMARAKOTI, S. **The AI cloud infrastructure blueprint: practical designs and configurations for scalable AI**. Abingdon, Oxon; New York: Routledge, 2025.

