Capítulo 4

Redes neurais convolucionais (CNNs)

Para Goodfellow (2016), redes convolucionais, também conhecidas como redes neurais convolucionais (convolutional neural networks – CNNs), são um tipo especializado de rede neural para processamento de dados com uma topologia conhecida, semelhante a uma grade.

Exemplos incluem dados de séries temporais, que podem ser considerados como uma grade unidimensional coletora de amostras em intervalos de tempo regulares, e dados de imagem, que podem ser considerados como uma grade bidimensional de pixels.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Veremos a seguir um pouco mais sobre suas características, como a estrutura básica e as formas de operação de uma rede neural convulacional. Veremos também as camadas e o pooling.

Por fim, o capítulo destacará as diferenças de desempenho e as aplicações práticas, assim como treinamento e avaliação de uma CNN e análise de melhores estratégias para uma maior performance e regularização.

1 Introdução às redes convolucionais

As redes neurais convolucionais são um marco no aprendizado profundo, especialmente em tarefas de visão computacional, devido à sua capacidade de aprender representações hierárquicas de dados (Geron, 2019).

Goodfellow (2016) nos ensina que as redes convolucionais têm sido muito bem-sucedidas em aplicações práticas. O nome "rede neural" convolucional indica que a rede emprega uma operação matemática chamada convolução.

Segundo Suave (2024), a convolução é um tipo especializado de operação linear. As redes convolucionais são simplesmente redes neurais que usam a convolução no lugar da multiplicação geral de matrizes em pelo menos uma de suas camadas.

1.1 O que são CNNs e como funcionam

Para Geron (2019), normalmente a operação usada em uma rede neural convolucional não corresponde precisamente à definição de convolução usada em outros campos, como engenharia ou matemática pura.

Ainda segundo o autor, as redes neurais convolucionais são redes neurais especializadas em processar dados com estrutura de grade,

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

como imagens ou séries temporais. Elas utilizam operações de convolução para extrair características locais, como bordas ou texturas, e camadas de pooling para reduzir a dimensionalidade, preservando informações relevantes.

A figura 1 mostra de forma simplificada o funcionamento de uma rede neural convolucional. O processo começa com a entrada de uma imagem; no nosso exemplo, um gato. Em seguida, a camada de convolução aplica filtros que extraem características visuais relevantes, como bordas, texturas e padrões.

Figura 1 – O que são CNNs: exemplo

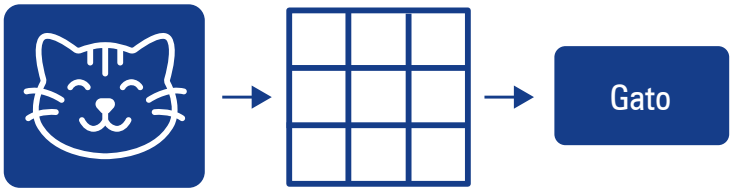

Esses filtros geram mapas de características, também chamados de feature maps, que destacam regiões importantes da imagem. Por fim, após o processamento pelas camadas da rede, a rede neural convolucional realiza a classificação, identificando o conteúdo da imagem e atribuindo uma saída correspondente; neste caso, a categoria “GATO”.

O exemplo demonstra como uma rede neural convolucional é capaz de transformar uma imagem bruta em uma representação numérica rica em informações, permitindo que o modelo reconheça objetos de forma automática e eficiente.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

IMPORTANTE

Suave (2024) nos ensina que, diferentemente das redes feedforward tradicionais, que tratam cada entrada independentemente, as CNNs exploram a estrutura espacial dos dados, aplicando filtros que detectam padrões em diferentes regiões. O processo é hierárquico, composto por camadas iniciais identificam características simples, enquanto camadas mais profundas capturam padrões complexos.

Esse aprendizado automático de características torna as redes neurais convolucionais altamente eficazes em tarefas como classificação de imagens e detecção de objetos.

1.2 Estrutura básica: camadas convolucionais, pooling e fully connected

Segundo Goodfellow (2016), a estrutura de uma rede neural convulacional é composta por três tipos principais de camadas: convolucionais, de pooling e fully connected.

As camadas convolucionais aplicam filtros (ou kernels) para extrair características, gerando mapas de ativação que destacam padrões como bordas ou texturas. Já as camadas de pooling reduzem a resolução espacial dos mapas de ativação, diminuindo o custo computacional e o risco de sobreajuste, enquanto mantêm as características mais relevantes.

As camadas fully connected, geralmente no final da rede, combinam as características extraídas para realizar tarefas como classificação. Por exemplo, em uma rede neural convulacional para classificação de imagens, as camadas iniciais detectam bordas, as intermediárias identificam formas e as finais classificam a imagem como “gato” ou “cachorro”.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

1.3 Diferenças entre CNNs e redes neurais tradicionais

Segundo os ensinamentos de Geron (2019), as redes neurais convolucionais diferem das redes neurais tradicionais em alguns aspectos. Primeiramente, enquanto redes neurais tradicionais tratam cada entrada como independente, as redes neurais convolucionais exploram a estrutura espacial dos dados, usando convoluções para capturar relações locais.

Isso reduz significativamente o número de parâmetros, tornando as redes neurais convolucionais mais eficientes para dados de alta dimensão, como imagens. Além disso, as redes neurais convolucionais utilizam camadas de pooling para reduzir a dimensionalidade, algo ausente em redes tradicionais, o que ajuda na generalização e diminui o custo computacional.

Para Suave (2024), as redes neurais convolucionais são invariantes a translações, ou seja, podem reconhecer padrões independentemente de sua posição na imagem, uma vantagem crítica em visão computacional.

2 Camadas convolucionais e pooling

Para Geron (2019), as camadas convolucionais e de pooling são os blocos fundamentais das redes neurais convolucionais, responsáveis por extrair e condensar informações dos dados de entrada. Veremos nas seções seguintes, de forma detalhada, o funcionamento dessas camadas, com foco nos filtros, na operação de convolução e nos mapas de ativação gerados.

2.1 Filtros e kernels: extração de características

Segundo Malik, Fatema e Alzubi (2021), os filtros (ou kernels) são pequenas matrizes; por exemplo, de 3 × 3 ou 5 × 5 aplicadas às camadas convolucionais para detectar características específicas, como bordas, texturas ou formas.

Para Silveira e Bullock (2017), cada filtro desliza sobre a entrada, calculando produtos escalares em regiões locais para gerar mapas de ativação. Por exemplo, um filtro pode destacar bordas horizontais ao atribuir pesos altos a mudanças abruptas de intensidade.

Durante o treinamento, os pesos dos filtros são ajustados para aprender as características mais relevantes para a tarefa. Múltiplos filtros em uma camada produzem vários mapas de ativação, cada um capturando um aspecto diferente dos dados.

2.2 Operação de convolução e mapas de ativação

A operação de convolução consiste em aplicar um filtro a uma região da entrada, somando os produtos elemento a elemento para gerar um valor no mapa de ativação (Geron, 2019). Matematicamente, para uma entrada (I) e um filtro (K), a convolução em uma posição ((i,j)) é dada por uma equação, sendo a operação de convolução em uma rede neural convolucional.

O resultado é um mapa de ativação que destaca onde o padrão detectado pelo filtro está presente. Após a convolução, uma função de ativação é aplicada para introduzir não linearidade, permitindo que a rede modele padrões complexos.

As camadas de pooling, como max pooling, reduzem a resolução dos mapas de ativação, selecionando o valor máximo em uma região; por exemplo, 2 × 2, o que diminui a dimensionalidade e aumenta a robustez

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

a pequenas variações nos dados (Malik; Fatema, Alzubi, 2021). São exemplos de IA reativa a limitada e a com aprendizado contextual.

3 Arquiteturas populares de CNNs

As arquiteturas de redes neurais convolucionais evoluíram significativamente, introduzindo designs que melhoram a precisão e a eficiência em tarefas de visão computacional (Geron, 2019). Veremos algumas das arquiteturas mais influentes e como podem ser utilizadas na prática.

3.1 AlexNet, VGG, ResNet e Inception

A partir de Goodfellow (2016), vejamos algumas de suas características a seguir:

- AlexNet – introduzida em 2012, a AlexNet revolucionou a visão computacional ao vencer o ImageNet com uma arquitetura de 8 camadas, usando ReLU, dropout e GPUs (Graphics processing units) para acelerar o treinamento. É conhecida por sua simplicidade e eficácia em classificação de imagens. Como breve explicação, o ImageNet é um conjunto de dados composto por mais de 14 milhões de imagens pertencentes a quase 1.000 classes.
- VGG (Visual Geometry Group) – desenvolvida em 2014, a VGG (VGG16 e VGG19) é uma arquitetura padrão de rede neural convolucional que usa camadas convolucionais menores; por exemplo, de 3 × 3, empilhadas para criar redes profundas, oferecendo alta precisão, mas com alto custo computacional.
    - VGG16 – proposto por A. Zisserman e K. Simonyan, da Universidade de Oxford, suporta 16 camadas e atinge quase 92,7% de precisão no teste top 5 do ImageNet.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- VGG19 – podemos dizer que o conceito do modelo VGG19 é o mesmo do VGG16, exceto por suportar 19 camadas. Isso significa que o VGG19 possui três camadas convolucionais a mais que o VGG16.

- ResNet – proposta em 2015, a ResNet introduz conexões residuais, permitindo redes muito profundas; por exemplo, de 152 camadas, sem problemas de gradiente evanescente, sendo amplamente usada em tarefas complexas.

- Inception (GoogleNet) – vencedora do ImageNet em 2014, a Inception usa módulos Inception para combinar filtros de diferentes tamanhos, reduzindo parâmetros e melhorando a eficiência.

3.2 Diferenças em desempenho e uso prático

Para Goodfellow (2016), as arquiteturas de redes neurais convolucionais diferem significativamente em termos de profundidade, complexidade computacional, eficiência e aplicações práticas, sendo cada uma projetada para atender a necessidades específicas em tarefas de visão computacional.

Vejamos a seguir uma análise mais expandida, quando comparada com a seção anterior, das arquiteturas AlexNet, VGG, ResNet e Inception, com base nas características, nos pontos fortes, nas limitações e nos cenários de uso, considerando os pontos fortes entre precisão, custo computacional e aplicabilidade.

A AlexNet marcou o início da popularização das redes neurais convolucionais, com 8 camadas (5 convolucionais e 3 totalmente conectadas). Ela utiliza filtros grandes (11×11 e 5 × 5) e técnicas como ReLU, dropout e data augmentation para melhorar a generalização.

Apesar de sua simplicidade em comparação com arquiteturas modernas, a AlexNet é computacionalmente intensiva devido ao grande número

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

de parâmetros (cerca de 60 milhões) e ao uso de camadas densas. É ideal para tarefas básicas de classificação de imagens, como reconhecimento de objetos em datasets menores; mas seu alto consumo de recursos a torna menos viável para dispositivos com hardware limitado ou para redes mais profundas.

Já as variantes da VGG são conhecidas por sua arquitetura uniforme, composta por 16 ou 19 camadas que utilizam filtros convolucionais menores (3 × 3) empilhados. Essa abordagem aumenta a capacidade de capturar detalhes finos, resultando em alta precisão em tarefas complexas, como segmentação de imagens ou detecção de objetos que exigem alta resolução.

No entanto, a VGG é extremamente custosa computacionalmente, com cerca de 138 milhões de parâmetros na VGG16, o que exige GPUs poderosas e longos tempos de treinamento. Por isso, é mais adequada para aplicações acadêmicas ou industriais em que a precisão é prioritária e os recursos computacionais não são uma limitação.

A ResNet, ou simplesmente Residual Network, foi proposta pela Microsoft em 2015 e revolucionou o treinamento de redes muito profundas ao introduzir conexões residuais (skip connections). Essas conexões permitem que camadas aprendam funções residuais, mitigando o problema do desaparecimento do gradiente e facilitando o treinamento de redes com centenas de camadas (como ResNet-50 ou ResNet-152).

Com menos parâmetros que a VGG (por exemplo, ResNet-50 tem cerca de 25 milhões de parâmetros), ela é mais eficiente e mantém alta precisão. A ResNet é amplamente utilizada em aplicações industriais, como sistemas de visão para carros autônomos, reconhecimento facial e análise de imagens médicas, devido à sua capacidade de equilibrar profundidade, desempenho e eficiência.

Desenvolvida pelo Google, a Inception, utiliza módulos Inception, que combinam diferentes tamanhos de filtros (1 × 1, 3 × 3, 5 × 5) e pooling

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

em paralelo, reduzindo o número de parâmetros (cerca de 7 milhões na Inception v1) e otimizando o uso de recursos computacionais.

Essa arquitetura equilibra precisão e eficiência, sendo ideal para cenários com restrições de hardware, como dispositivos móveis ou sistemas embarcados. Suas variantes, como Inception-v3 e v4, incorporam melhorias como normalização em lote e fatoração de convoluções, aumentando ainda mais a eficiência, muito usada em aplicações que requerem rapidez e precisão, como classificação em tempo real ou sistemas de recomendação visual.

A escolha entre essas arquiteturas depende de fatores como o problema em questão, os recursos computacionais disponíveis e a necessidade de precisão. A AlexNet é adequada para prototipagem rápida ou tarefas simples, mas seu alto consumo de memória a torna obsoleta para aplicações modernas.

A VGG é ideal para tarefas que demandam alta precisão em detalhes, como análise de texturas ou imagens médicas, mas é inviável para dispositivos com baixa capacidade computacional.

A ResNet é uma escolha robusta para aplicações industriais e de larga escala, enquanto a Inception é preferida em cenários com restrições de recursos, como dispositivos IoT (internet of things) ou aplicações móveis. Estudos recentes reforçam que a escolha deve considerar não apenas a precisão, mas o custo energético e a escalabilidade.

PARA PENSAR

Com base em tudo o que foi apresentado, quais outros exemplos práticos poderíamos trazer à tona para a aplicabilidade de CNNs?

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

4 Treinamento e avaliação de CNNs

Segundo Geron (2019), o treinamento de redes neurais convolucionais (CNNs) é um processo considerado complexo, que exige a aplicação de estratégias específicas para otimizar o desempenho, melhorar a generalização e mitigar problemas como o sobreajuste, também conhecido como overfitting.

Nesta seção, o objetivo é detalhar alguma das técnicas utilizadas para aprimorar a performance das CNNs, incluindo métodos de aumento de dados, normalização, escolha de otimizadores e também transferência de aprendizado, além de abordar regularização e dropout como ferramentas essenciais para garantir modelos robustos e eficientes. Por fim, veremos métricas e práticas para validar o desempenho dos modelos.

4.1 Estratégias para melhorar a performance em CNNs

Segundo Ioffe e Szegedy (2015), para alcançar melhores resultados no treinamento de CNNs, podemos usar algumas estratégias, cada uma abordando diferentes aspectos do processo de aprendizado. Essas técnicas visam melhorar a convergência do modelo e, segundo Goodfellow (2016), aumentar sua capacidade de generalização e reduzir a dependência de grandes quantidades de dados rotulados. Vejamos algumas das abordagens:

- Data augmentation – essa técnica, também conhecida como aumento de dados, é fundamental para combater o sobreajuste, especialmente em datasets limitados. Por meio de transformações como rotação, espelhamento horizontal ou vertical, corte aleatório (random cropping), mudança de brilho, contraste, saturação e translações, o aumento de dados cria variações artificiais das imagens de treinamento. Isso permite que a rede seja exposta a uma maior gama de exemplos, aprendendo representações mais

completas e generalizáveis. Por exemplo, em tarefas de classificação de imagens, o espelhamento horizontal pode simular diferentes orientações de um objeto, enquanto mudanças de iluminação ajudam a rede a lidar com variações de luz em cenários reais. Além disso, conta com técnicas avançadas, como cutout, em que são removidas partes aleatórias da imagem, e mixup, em que há a combinação linear de imagens. Ambas têm se mostrado eficazes em aumentar a robustez do modelo.

- Normalização de dados – crucial para acelerar a convergência e estabilizar o treinamento. Em redes neurais convolucionais, isso geralmente envolve escalonar os valores dos pixels das imagens para um intervalo padrão, como [0, 1] ou [-1, 1], ou normalizar os dados para que tenham média zero e desvio-padrão unitário (z-score normalization). Essa prática reduz a variabilidade nos dados e facilita a otimização, já que os gradientes se comportam de maneira mais previsível. Por exemplo, em imagens RGB, os valores de pixel (0 a 255) são frequentemente divididos por 255 para serem escalonados para [0, 1]. Além disso, a normalização por canal, que é baseada na média e desvio-padrão de cada canal de cor, é comum em modelos pré-treinados, como VGG ou ResNet, para garantir consistência com os dados usados no treinamento original.

- Otimizadores avançados – a escolha do algoritmo de otimização impacta diretamente a velocidade e a qualidade do treinamento. Enquanto o gradiente descendente estocástico (SGD – stochastic gradient descent) tradicional é eficaz, ele pode ser lento em redes profundas devido à necessidade de ajustar cuidadosamente a taxa de aprendizado. Otimizadores adaptativos, como Adam (adaptive moment estimation) e RMSProp, são preferidos em redes neurais convolucionais modernas porque ajustam dinamicamente a taxa de aprendizado com base nos momentos dos gradientes, como média e variância. O Adam, por exemplo, combina o momento de

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

acelerar a convergência em direções relevantes com a adaptação da taxa de aprendizado por parâmetro, resultando em convergência mais rápida e estável. Outras variantes, como AdamW, que incorpora regularização L2 diretamente, e o AdaGrad, também são usadas em contextos específicos, dependendo do problema e da arquitetura.

- Transfer learning – também conhecida como transferência de aprendizado, é uma técnica que pode ser particularmente útil quando o conjunto de dados disponível é pequeno ou o treinamento do zero seria computacionalmente caro. A transferência de aprendizado consiste em utilizar pesos pré-treinados de modelos robustos, como ResNet, VGG, ou Inception, que foram treinados em grandes datasets, como ImageNet. Esses pesos iniciais contêm representações genéricas de características visuais, como bordas, texturas e formas complexas, que podem ser adaptadas para tarefas específicas por meio de fine-tuning, em que as camadas iniciais do modelo que capturam características genéricas são frequentemente congeladas, enquanto as camadas finais, que capturam características específicas da tarefa, são treinadas novamente. Essa abordagem economiza tempo, reduz a necessidade de grandes quantidades de dados e melhora a performance em tarefas como classificação de imagens médicas ou detecção de objetos em cenários industriais (Geron, 2019).

4.2 Regularização e dropout em redes convolucionais

A regularização é um componente essencial no treinamento de redes neurais convolucionais para evitar o sobreajuste, que ocorre quando o modelo aprende padrões específicos do conjunto de treinamento, mas falha em generalizar para dados novos (Ioffe; Szegedy, 2015). Vejamos alguma das técnicas de regularização e seus impactos:

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Dropout – técnica poderosa que desativa aleatoriamente uma fração dos neurônios em uma camada durante cada iteração do treinamento; por exemplo, com uma probabilidade de 50%. Isso força a rede a aprender representações redundantes e robustas, já que nenhum neurônio pode ser excessivamente dependente de outros. O dropout é especialmente eficaz em camadas totalmente conectadas, mas também pode ser aplicado em camadas convolucionais em arquiteturas modernas. Durante a inferência, todos os neurônios são utilizados, mas os pesos são escalonados para compensar a ausência de dropout. Essa técnica melhora a generalização e é amplamente usada em arquiteturas como AlexNet e VGG.

- Regularização L2 – também conhecida como penalização de peso, a regularização L2 adiciona um termo à função de perda que penaliza a magnitude dos pesos da rede. Essa penalidade desencoraja pesos excessivamente grandes, promovendo soluções mais simples e reduzindo o risco de sobreajuste. A regularização L2 é frequentemente combinada com otimizadores como AdamW, que integra a penalidade diretamente no processo de otimização, garantindo um equilíbrio entre aprendizado e controle de complexidade.

- Batch normalization – é uma proposta de Ioffe e Szegedy (2015). A normalização em lote (batch normalization) normaliza as ativações de cada camada para que tenham média zero e variância unitária, com base nas estatísticas do lote atual. Isso é feito durante o treinamento e ajustado por parâmetros aprendíveis, como a escala e deslocamento. A normalização em lote acelera o treinamento, reduz a sensibilidade à inicialização dos pesos e estabiliza os gradientes, permitindo taxas de aprendizado mais altas. Além disso, ela atua como uma forma de regularização implícita, reduzindo a necessidade de dropout em alguns casos. Essa técnica é bastante adotada em arquiteturas modernas, como ResNet e Inception, e é essencial para o treinamento de redes profundas.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

- Outras técnicas de regularização: além das mencionadas, outras abordagens incluem a regularização L1, que promove esparsidade nos pesos; early stopping, que é útil ao parar o treinamento quando a performance no conjunto de validação para de melhorar; e label smoothing, para suavizar rótulos para evitar overconfidence. Essas técnicas, quando combinadas, aumentam a robustez do modelo e sua capacidade de generalização em cenários reais, segundo Goodfellow (2016).

Podemos afirmar que a avaliação do desempenho de redes neurais convolucionais é tão importante quanto o treinamento. Métricas como acurácia, precisão, recall, F1-score e AUC-ROC são usadas para avaliar a performance em tarefas de classificação, enquanto métricas como IoU (intersection over union) são comuns em tarefas de segmentação.

O conjunto de validação é usado para monitorar o treinamento e evitar sobreajuste, enquanto o conjunto de teste fornece uma avaliação final do modelo. Técnicas como validação cruzada (k-fold cross-validation) podem ser empregadas em datasets menores para garantir resultados robustos.

Além disso, ferramentas de visualização, como mapas de calor, também conhecidos como heatmaps, gerados por Grad-CAM, ajudam a interpretar as decisões do modelo, identificando quais regiões da imagem são mais relevantes para a predição.

Considerações finais

Neste capítulo, buscamos apresentar uma análise detalhada das redes neurais convolucionais, com ênfase em suas arquiteturas, estratégias de treinamento e técnicas de avaliação, destacando suas características, especificidades e aplicações práticas.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.

Por fim, citamos exemplos de arquiteturas importantes, como AlexNet, VGG, ResNet e Inception, discutindo suas diferenças em profundidade, complexidade e eficiência. Também abordamos estratégias importantes para otimizar o treinamento de redes neurais convolucionais, incluindo aumento de dados, normalização e uso de otimizadores.

Referências

GERON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**: Concepts, Tools, and Techniques to Build Intelligent Systems. [*S. l.*]: O'Reilly Media, 2019.

GOODFELLOW, I., BENGIO, Y., COURVILLE, A. **Deep Learning**. The MIT Press, 2016.

IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, Lille, 32., 2015. **Anais** [...].

MALIK, Hasmat; FATEMA, Nuzhat; ALZUBI, Jafar A. **AI and Machine Learning Paradigms for Health Monitoring System**. Varsóvia: Springer, 2021.

SILVEIRA, G.; BULLOCK, B. **Machine learning**: introdução à classificação. São Paulo: Casa do Código, 2017.

SUAVE, A. A. **Inteligência artificial**. São Paulo: Editora Freitas Bastos, 2024.

Material para uso exclusivo de aluno matriculado em curso de Educação a Distância da Rede Senac EAD, da disciplina correspondente. Proibida a reprodução e o compartilhamento digital, sob as penas da Lei. © Editora Senac São Paulo.